ИИ для заполнения характеристик товаров

Текст карточки превращается в проверяемые атрибуты: значение, источник, метод, уверенность и статус

Рабочий веб-прототип на данных SKU, описаний и кликов

15 октября 2026

ВОПРОС 1 · ЗАДАЧА БИЗНЕСА И ПОЛЬЗОВАТЕЛЬ

Товар есть в каталоге, но не находится по фильтру

Продавцы присылают текстовые карточки с пропущенными, разнородными и противоречивыми характеристиками.

Задача

Извлечь из названия, описания и полей продавца значения атрибутов. Привести их к формату каталога и не принимать неподтверждённое.

Основной пользователь

Модератор каталога проверяет спорные значения. Продавец видит результат при загрузке карточки; покупатель получает более полный фильтр.

1 177 200

SKU с названием и описанием

6 963

категории таксономии

30 991 350

строк запрос–SKU в кликах

Почему это важно

Заполненный атрибут помогает товару попасть в фильтры, сравнение и рекомендации. Ложный атрибут ухудшает поиск, поэтому сомнительные значения отправляются на проверку.

Что нужно для надёжного заполнения карточки

Один входной объект: название, описание, атрибуты продавца; ID категории может отсутствовать. Изображения не используются.

Обязательные поля

Бренд и модель; для смартфона также память, диагональ, батарея и цвет. Для ноутбука процессор, ОЗУ, накопитель, диагональ и цвет.

Проверяемый выход

JSON и таблица: каноническое значение, исходная цитата, поле-источник, метод, уверенность и статус accepted / review / missing.

Контроль ошибок

Значение принимается только при подтверждении во входном тексте и соответствии схеме. Конфликт и низкая уверенность идут на ручную проверку.

Языки и единицы

Правила покрывают RU/EN варианты, GB/ГБ, десятичную запятую и цвета. Размеры одежды EU, US и RU сохраняются как отдельные поля.

Масштаб и новые категории

Дешёвые правила работают первыми. ML цвета исследован отдельно; LLM предусмотрена только для сложных пропусков с проверкой по тексту.

ВОПРОС 2 · СТАДИЯ И ГРАНИЦЫ ПРОТОТИПА

Что уже работает и чего пока нет

Статус важен для оценки брифа: техническая работоспособность не равна измеренному качеству на независимом эталоне.

Работает сейчас

Веб-интерфейс и API; выбор 110 реальных SKU; извлечение правилами и словарями; нормализация; проверка цитаты и конфликтов; статусы; пакетный JSON по 1 177 200 SKU.

Ограничения сейчас

Нет официального перечня обязательных полей для всех категорий, независимого human gold, показов и событий фильтров. LLM не настроена; ML цвета остаётся экспериментом. Качество на китайском тексте не проверено.

Следующий шаг

Получить официальный список обязательных атрибутов и человеческую разметку. Затем посчитать precision, recall и F1 по каждому полю, редким категориям и продавцам; выбрать пороги автоматического принятия.

ВОПРОС 3 · ОСНОВНОЙ СЦЕНАРИЙ

От текста SKU до поля каталога

Сервис можно вызвать из браузера или через POST /api/extract.

01 Карточка

Название, описание, поля продавца, необязательная категория.

02 Схема

Справочник определяет допустимые атрибуты категории.

03 Извлечение

Правила и словари ищут явные значения в тексте.

04 Нормализация

Единицы, цвета и варианты записи приводятся к одному виду.

05 Контроль

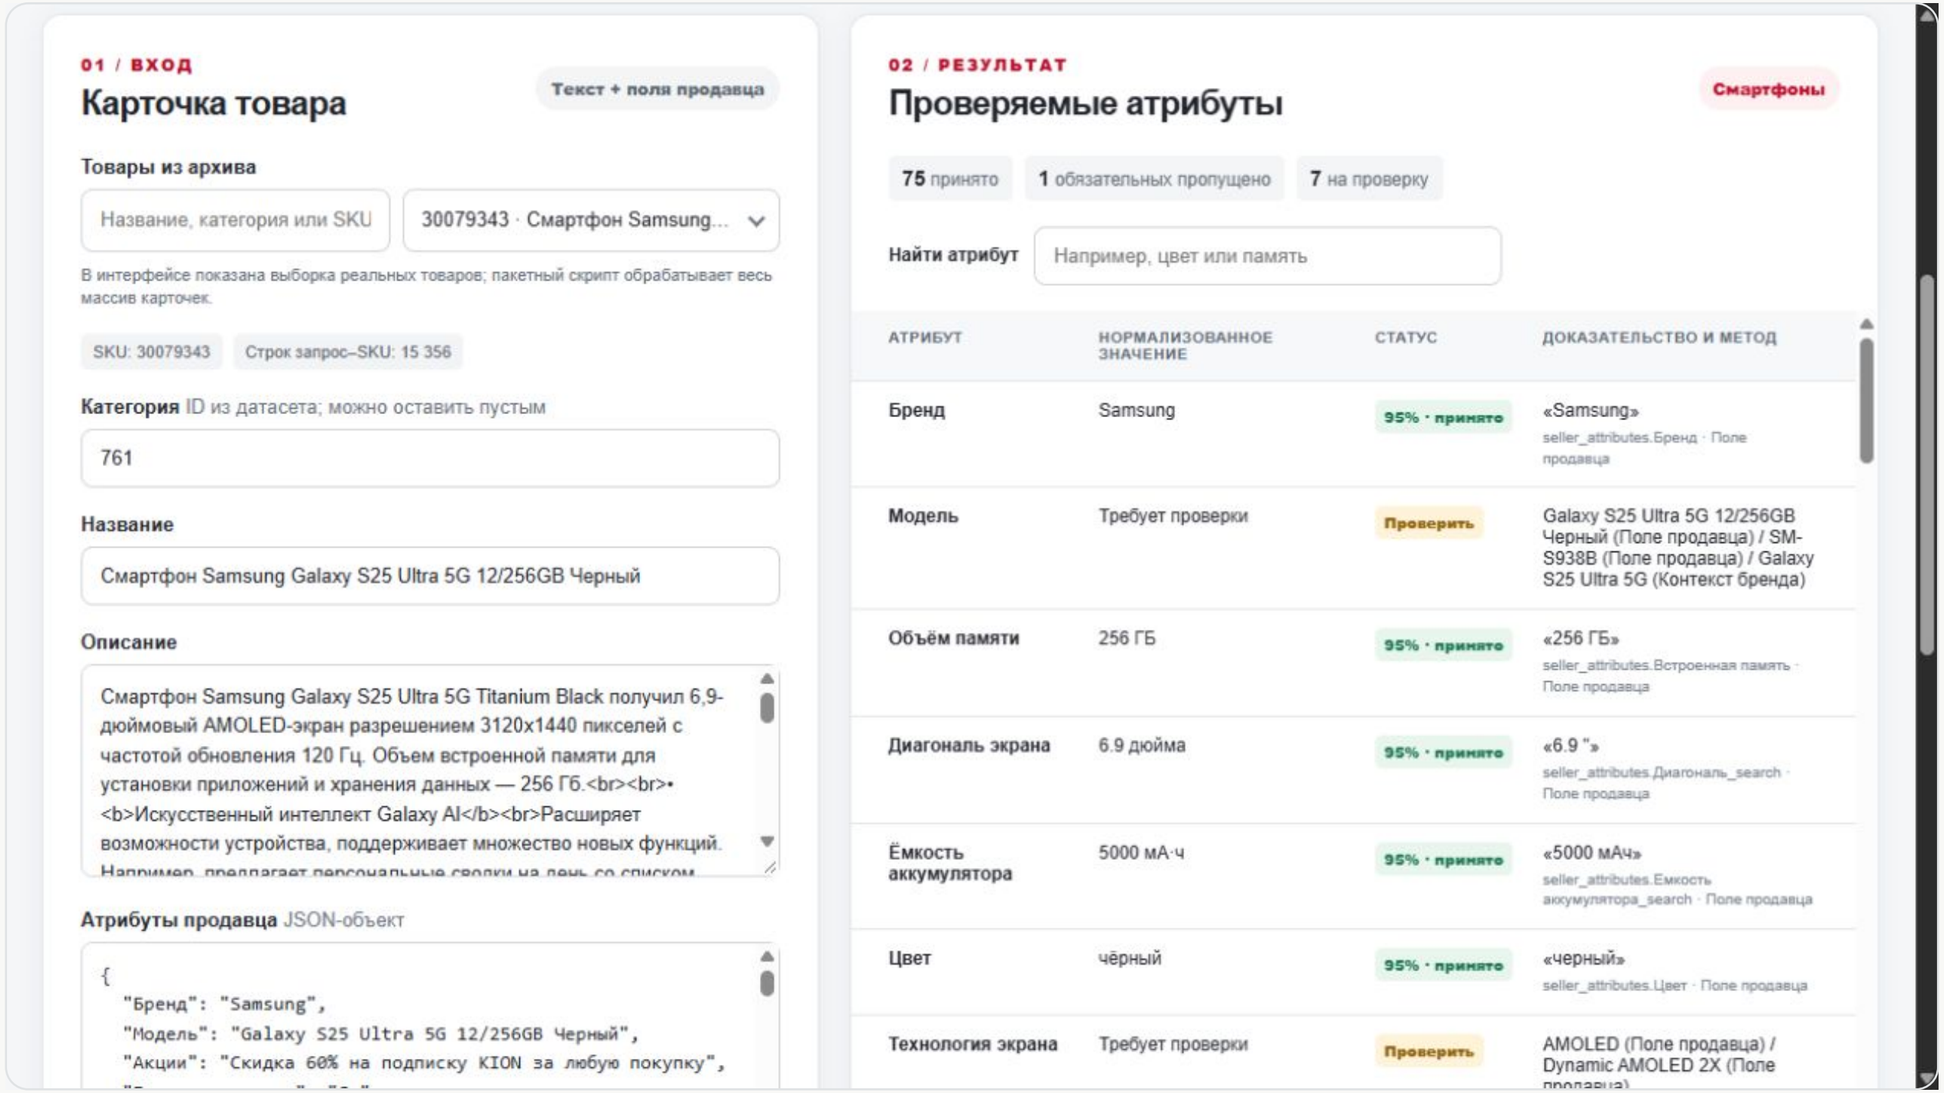
Цитата, источник, конфликт и метод определяют статус.

06 Результат

Таблица для модератора и JSON для API; сомнительное — на проверку.

Правки модератора могут возвращаться в словари и разметку; этот цикл ещё требует данных human gold.

Результат на реальной карточке SKU 30079343



Окно JSON для интеграции через API

СТРУКТУРА ДЛЯ ИНТЕГРАЦИИ

JSON для API

Результат для текущей карточки: значения, источники, методы, уверенность и статусы.


```
{
  "id": "30079343",
  "category": {
    "value": "761",
    "label": "Смартфоны",
    "method": "provided_category_id",
    "confidence": 1
  },
  "attributes": {
    "brand": {
      "attribute": "brand",
      "value": "Samsung",
      "raw": "Samsung",
      "source": "seller_attributes.Бренд",
      "method": "seller_field",
      "confidence": 0.95,
      "evidence": {
        "field": "seller_attributes.Бренд",
        "text": "Samsung"
      },
```


Копировать JSON

Меньше пустых полей, понятнее проверка

Экономический эффект пока не измерен на показах, фильтрах и продажах.

Модератор

Видит источник, цитату и метод рядом со значением. Проверяет конфликты вместо ручного чтения всей карточки.

Продавец

Получает структурированный результат и список ключевых полей, которым не хватило подтверждения.

М.Видео

Получает основу для более полного каталога, фильтров, сравнения и рекомендаций без автоматической публикации спорных значений.

Пример на реальном смартфоне

Для SKU 30079343 подтверждены бренд, память, диагональ, батарея и цвет. Поле «модель» отправлено на проверку из-за несовпадения записей. Это пример работы маршрутизации, а не оценка точности на всём каталоге.

ВОПРОС 5 · МЕТРИКИ УСПЕХА

Качество считаем по каждому атрибуту

Нужен независимый gold-набор, размеченный людьми отдельно по категориям.

ПОКАЗАТЕЛЬ	КАК СЧИТАЕМ	СТАДИЯ СЕЙЧАС
Precision / recall / F1	По каждому атрибуту, включая редкие значения	Пока нет human gold
Coverage	Доля карточек с корректно заполненным полем	Техническое заполнение есть
Трафик и фильтры	Взвесить поля по реальному использованию фильтров	Есть клики, нет фильтров
Редкие категории	Отдельный срез human gold по категориям	Требуется разметка
Продавцы	Качество крупных и малых продавцов отдельно	Требуется разметка

Клики без показов не дают CTR. Метрики по полям каталога — silver-проверка, не независимый gold.

Проверяемые атрибуты уже можно получить из карточки

API + UI

извлечение на реальном SKU

1 177 200

SKU в пакетном JSON

8 / 8

автотестов проходят

Следующая проверка: официальный перечень полей и human gold, затем пороги по каждому атрибуту и категории. Публикация сомнительных значений остаётся на ручной проверке.

Рабочий прототип: mvideo-attribute-ai.vercel.app